请求级保证投放广告计划：预测和分配

作者：Hong Zhang , Lan Zhang , Lan xu , Xiaoyang Ma , Zhengtao Wu , Cong Tang , Wei Xu , Yiguo Yang

摘要

保证投放模式在网络广告中得到广泛应用。出版商预先出售印象，承诺在固定的时间内为每个广告客户提供数量一致的目标印象，这些目标印象满足特定的属性要求。以前的工作通常是将服务建模为群体层面或用户层面的供应分配问题，并专注于搜索在线服务的最优分配，假设供应预测是可用的，并且已经签订了合同。现有的技术已经不能满足当今行业趋势的需求:1)广告商追求更精准的定位，不仅需要用户级属性，还需要请求级属性;2)用户喜欢更友好的广告服务，这就增加了服务约束的多样性;3)发行商收入增长的瓶颈不仅在于广告服务，还在于预测的准确性和销售策略。这些问题需要解决，因为请求级模型的规模要比人群级或用户级模型大几个数量级。面对挑战，我们提出了一个整体设计的请求级保证交付广告计划系统，并仔细优化所有三个关键组成部分，包括印象预测，销售和服务。我们的系统已部署在腾讯在线保送广告系统中，服务亿级用户近一年。
对大规模真实数据的评估和部署系统的性能都表明，我们的设计可以显著提高请求级印象预测准确性和交付率。

CCS 概念

•信息系统→计算广告;•计算理论→学习模型。

关键词

保证交付广告;请求级别印象预测;广告配置

1 介绍

很大一部分在线展示广告是以有保证的方式出售的。在一个典型的保证投放广告的过程中，广告商订购一定数量的广告印象，并在未来的特定时期内以特定的属性向用户展示。发布者需要以某种(近乎)最优的方式完成以下三项任务:1)在规定时间内预测库存(符合条件的印象机会);2)提前几个月/几个星期确定可保证的最大印象机会数量，签订合同，销售预测库存;3)在用户的实际请求到达时，通过在瞬间的延迟中确定每个机会应该在数千个符合条件的合同中显示哪一个，实时提供广告。即使是销售数量或交付率的几个百分点的提高，也可以增加出版商数千万美元的收入，以及增加广告客户的投资回报。然而，过度销售将导致交货不足和罚款。

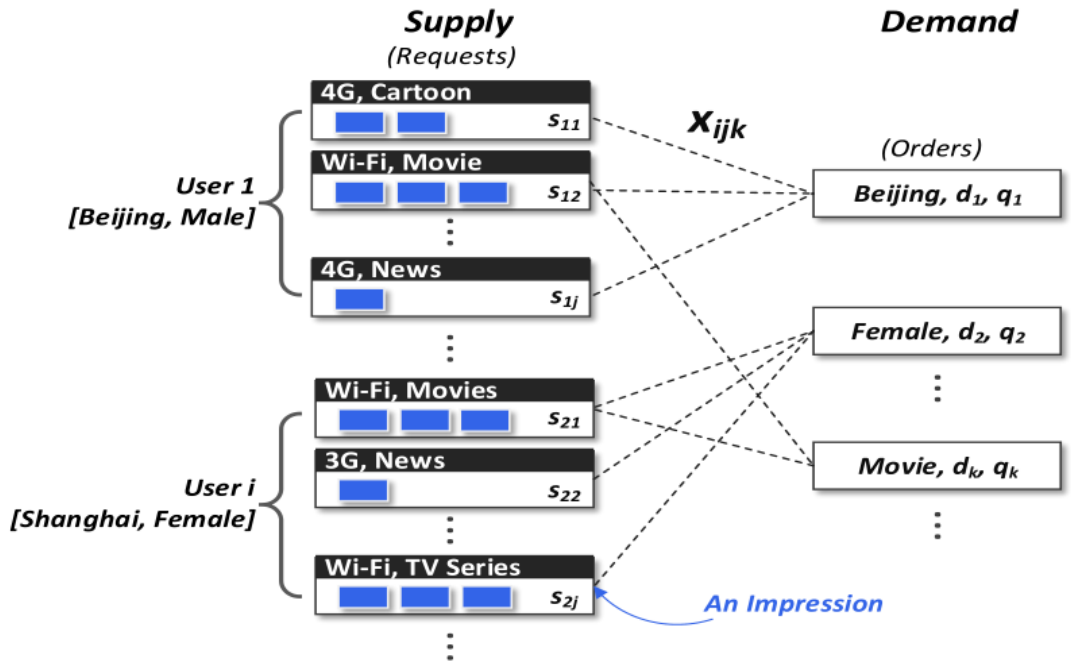


图 1:用户请求和订单的示例。每个用户可能有不同印象数量的异构请求。虚线表示请求中的印象符合所连接的顺序。

在保证配送广告的优化方面已经付出了很多努力[2,4,5,7,8,10,12]。然而，行业趋势表明，现有的方法不能满足广告主、用户和发布者在以下方面的需求:第一，大多数工作是制定和解决人群层面的预测和分配问题[2,4,7,8,10,12]。最近的一些工作开始考虑用户级分配[5]。在现实中，广告商总是追求更精确的定位。例如，广告商可能会瞄准上海的女性 iPhone 用户，通过 Wi-Fi 连接观看特定的流行电视节目。如图 1 所示，每个用户可能有异构请求，不同的请求可能有不同数量的印象机会。为这样的广告商服务不仅需要群体级/用户级的属性，还需要请求级的属性，比如内容的名称和网络状况。根据腾讯在线视频广告的统计，45%的订单需要进行请求级定向。请求级属性组合的规模比用户级属性组合的规模大几个数量级，使得现有方法无法有效地解决预测和分配问题。其次，之前关于保证递送广告的研究主要集中在假设印象预测和合同已经存在的情况下，如何有效地实现在线服务的最佳分配。尽管印象预测错误和销售策略对广告服务绩效的影响不可忽视[2,4,5,12]，但很少有研究深入到用户级别[10]的大规模印象机会预测和销售问题，更不用说在请求级别了。第三，广告商和用户都希望有更多定制化和用户友好化的服务约束。大多数分配算法都是针对特定的约束进行定制的，因此很难支持定制的约束。

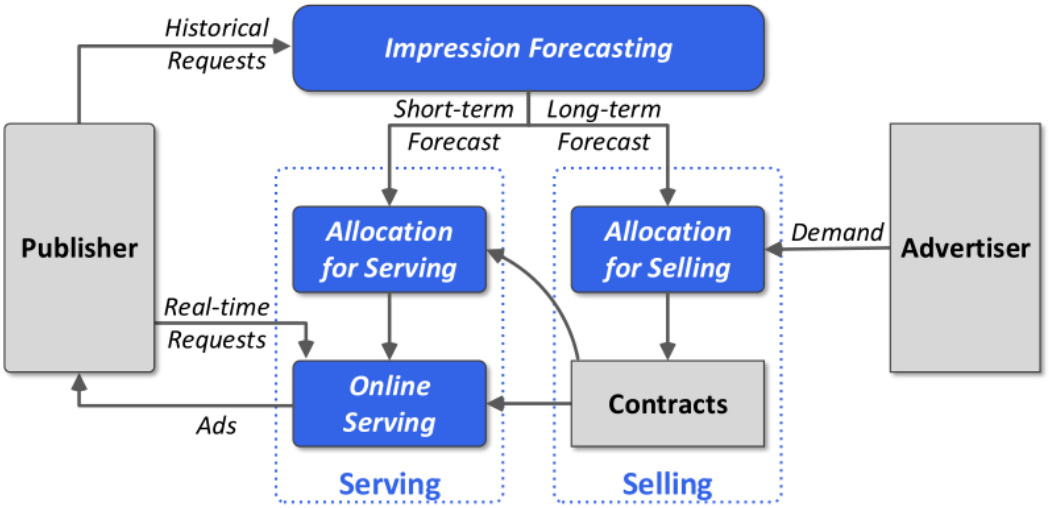


图 2:我们基于请求的保证投放广告计划系统 RAP 的结构。

基于更精准的广告投放目标和更人性化的服务约束，我们从更全面的角度设计了一个请求级保证投放广告计划系统(RAP)，旨在优化三个关键组成部分，包括印象预测、销售和服务。图 2 说明了我们的系统结构。主要部分集中于解决下列两个具有挑战性的问题：

1. ***大规模的请求级印象预测。***大规模高维数据预测是一个公认的具有挑战性的问题。在我们的例子中，请求级属性组合的维度比最先进的工作[10]大了几个数量级。在腾讯的广告系统中，每天有 10 亿水平的印象。有效的用户属性组合个数为 63,901 个，有效的请求属性组合个数为 4,254,119 个，可能的目标空间非常大。此外，由于用户行为的异质性，历史印象非常少。因此，预测请求级别的印象需要大量的计算资源和重要的特性来描述稀少和不同的请求。

2. ***定制线性约束下的销售和服务的大规模请求级印象分配。***即使我们有完美的预测，分配问题的规模是数百亿印象和成千上万合同的笛卡尔积，这使得在短时间内实现(接近)最优分配非常具有挑战性。在销售阶段，分配天数的延迟应该小于 1 分钟。在服务阶段，分配的延迟应该小于数百毫秒。任意定制服务约束进一步增加了求解大规模优化问题的难度。

我们的贡献可以总结如下。

(1)整体设计了一个大规模的请求级保送广告策划系统，包括精细印象预测和分配优化，用于销售和服务。我们的设计允许目标属性的粒度更细，从用户级到请求级，从而产生更精确的广告。它还支持更复杂的定制广告服务约束。我们认为，在不牺牲效率的情况下增加了灵活性，这将大大有利于广告商、用户和发行商。

(2)提出了聚类和张量分解相结合的方法，实现了准确的请求级印象预测，并明显降低了时间复杂度。对于大规模分配，我们使用一组定制的线性约束来解决优化问题，并设计了一种基于参数共享的并行算法和 GPU 加速方法来显著提高问题的求解速度。我们精心设计了印象销售和广告服务的目标功能。基于我们的算法，我们利用 lambda 架构在短时间内支持销售和服务。我们还结合了实时反馈来改善在线服务的分配。

(3) RAP 已在腾讯在线保送广告系统中部署近一年。我们根据数十亿用户请求和数千份合同的真实数据广泛评估我们的系统。实验和在线结果都表明，我们的预测方法优于最先进的方法，我们的分配解决方案在交付率和播放率上取得了显著的改善，这带来了可观的收入增长。

2 相关工作

我们的工作与现有的两类工作有关:时间序列预测和保证交付广告分配。

时间序列预测。传统的时间序列预测方法已被证明不适用于处理稀疏高维[10]数据。最近，矩阵因子分解模型[1,3]被提出来解决时间序列预测问题。Yu 等人[1]设计了一种用于高维噪声数据预测的时间正则化矩阵分解(TRMF)框架。Ma 等人[10]提出了一种时空张量因子分解模型(STTF)，该模型在大规模高维数据上实现了最先进的性能。在[10]中，解决了人群级用户访问预测，预测张量的规模为万。在我们的请求级印象预测问题中，张量的规模大了几个数量级，使得现有的方法不可行。

保证投放广告的分配。分配问题通常被认为是一个随机优化问题，在这方面已经有很多基础性的研究工作[6,9,11]。受这些工作的启发，许多实用的算法被提出来解决有保障的显示广告的分配问题。假设对未来库存有一个完美的预测，[12]可以创建一个紧凑的可证明的最优分配计划。标准的方法对于大规模的商业广告应用来说太慢了。高水位标记(HWM)[4]是一种基于贪婪启发式的更高效的算法，它牺牲了最优性。为了在运行时间和最优性之间取得更好的权衡，SHALE[2]引入了最优双值设计了两阶段迭代算法，从而快速逼近最优解。[8]采用列生成方案来解决有到达和频率约束的问题。Zhang 等人[14]提出了一种消费最小化模型，其核心是最小化满足所有契约所消耗的用户流量。最近，Fang et al.[5]提出了一个个性化的交付框架，该框架在用户层面模拟了具有个人频率和插槽约束的分配问题。所有这些工作都是在人群水平或用户水平上建立分配模型,其中许多依赖于库存预测的准确性。在我们的问题中，我们考虑了请求级目标，这大大增加了预测和分配问题的规模和复杂性。此外，大多数的分配方式都是针对广告服务和特定的约束条件而定制的。它们既不能直接解决销售阶段的分配问题(问题的制定和目标不同)，也不容易支持各种定制服务约束。实际上，那些带有特定约束的用户级模型(如[5])是带有定制约束的请求级模型的特例。

3 问题和系统概述

一个典型的广告策划问题可以用二部图来表示，如图 1 所示。在供应方面，用户请求提供了印象机会。这些印象机会的概况由用户的属性(例如，性别、年龄、收入水平和地区)和请求本身的属性(例如，时间、网络状况、内容类型和内容名称)组成。用户请求是异构的，即使是针对单个用户。例如，用户 i 是来自上海的女性用户。她的 j 型要求是通过 Wi-Fi 连接看电视剧。在这类请求中，她创造了三个给人留下印象的机会。s_{ij}表示用户 i 的类型 j 的请求所提供的印象总量。注意，一种请求类型是一组具有相同属性的请求。在需求方面，每个订单都以特定类型的印象为目标。在图 1 中，订单 k 以用户对电影请求的印象为目标。这需要一定程度的印象 d_k。q_k是服务约束的集合(例如，到达和频率)。当且仅当供应节点所代表的印象符合需求节点所代表的订单时，就添加一条从供应节点到需求节点的边。在保证投放广告中，广告商会提前几个月或几个星期预订印象机会，并指定广告服务时间。因此，发行商需要预测库存，在销售阶段将印象机会分配给每个订单，在服务阶段将实际印象分配给每个签订的合同。x_{ijk}表示分配给订单/合同 k 的用户 i 的第 j 类请求中印象所占比例。发行商的最终目标是优化自己的收益以及广告商和用户的体验，在服务限制下出售和提供尽可能多的合格印象。

为了实现这一目标，我们提供了一个全面的系统设计，用于请求级保证显示广告规划(见图 2)，名为 RAP，包含以下核心组件:

(1)印象预测:根据历史印象，在签订合同前，出版商进行长期预测，估计广告的可用库存s_{ij}和订单服务时间;在投放广告之前，出版商还需要一个s_{ij}的短期预测来优化广告的分配。

(2)销售印象分配:当新订单 k 到达时，在s_{ij}的长期预测下，发布者应寻找最优的x_{ijk}派别,以最大限度地满足约束q_k下的新需求d_k，同时最大限度地减少对现有合同的负面影响。

(3)印象分配服务:为了达到最佳的广告服务,出版商需要在s_{ij}的短期预测的基础上生成一个紧凑的分配计划的短期预测x_{ijk}。当一个请求到达时,给定一组的符合条件的合同,分配计划和实时反馈,出版商必须决定最优合同服务请求中的印象。

4 印象预测

保证投放广告的最佳销售和服务都是以印象预测为基础的。在本节中，我们将介绍一种有效的请求级别印象预测方法。

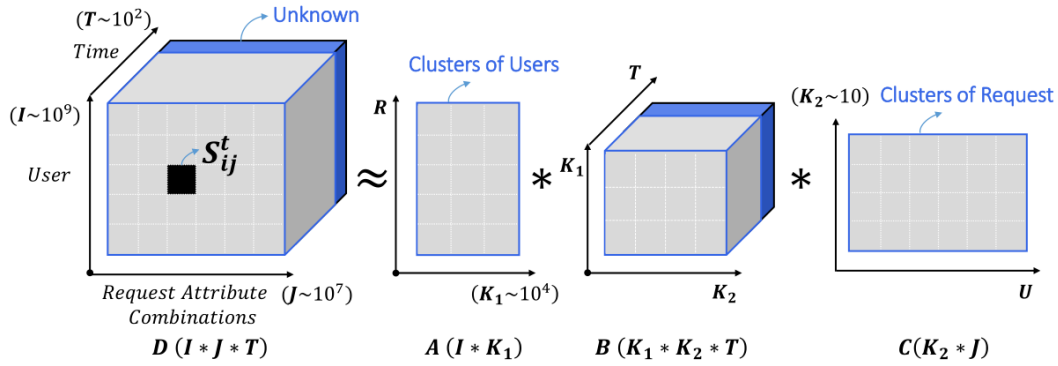


图 3:基于聚类和张量因子分解的请求级印象机会预测。

一般来说，保证送货广告是以日为单位销售的，所以在我们的预测问题中，我们以日为最小的时间单位。让我们用S_{ij}^t表示用户 i 在第 t 天的 j 类请求的全部印象，t 天总库存是一个集合$D^t = (S_{ij}^t | i \in I, j \in J)$. i 和 j 分别是用户和请求类型的指标集合。已知历史 n 天库存$D^1, D^2, \dots, D^N$,我们的目标是预测未来 M 天库存$D'^{N+1}, D'^{N+2}, \dots, D'^{N+M}$,使损失函数$L(D'^{N+1}, \dots, D'^{N+M})$最小。

直观上，损失函数可以定义为真实印象与预测印象之间的L_1差:

$$L(D'^{N+1}, \dots, D'^{N+M}) = \frac{1}{M}\frac{1}{|I|}\frac{1}{|J|}\sum_{t=1}^{M}\sum_I\sum_J |S_{ij}'^{N+t} - S_{ij}^{N+t}|,$$

其中S_{ij}'表示预测印象的数量。

理论上，我们可以根据张量因式分解的思想，通过使损失函数最小化来解决预测问题。如图 3 所示，我们可以用 3-rd 阶张量$D \in \mathbb{R}^{I*J*K}$来表示印象派$D^1, D^2, \dots, D'^{N+M}$有三种模式，即用户、请求属性组合(请求类型)和日期。这里 I 和 J 分别表示用户的数量(约为10^9)和请求属性组合(约为10^7)。T 表示总天数数据。那么S_{ij}^t是 D 的一个元素。我们可以通过探索使损失函数最小化的最佳张量因式分解来预测未知库存$\{S_{ij}^t | t > N\}$（张量 D 图 3 中的蓝色部分)。然而，损失函数是不切实际的，现有的张量分解模型(如最先进的工作 ST-TF[10])不能直接采用。原因是我们问题中的请求级张量的维数比 ST-TF[10]中的大几个数量级，并且稀疏得多，使得现有模型不可行。

为了处理高维和稀疏性，我们将聚类融入到张量分解中，并根据现有契约的目标改进损失函数。

聚类张量因子分解。如图 3 所示，我们将原始张量 D 分解成两个时间独立的因子矩阵$A \in \mathbb{R}^{I*K_1}$和$C \in \mathbb{R}^{K_2*J}$，以及一个更小的张量$B \in \mathbb{R}^{K_1*K_2*T}$。我们将新增加的维$K_1$作为用户的聚类，A 作为用户群中每个用户的条件概率分布。同样，我们将新增加的维K_2作为用户请求的聚类，将维 C 作为请求簇中每个请求属性组合的条件概率分布。那么我们可以把张量 B 看作是用户群和请求群随时间变化的联合概率分布。这样，我们将原来的预测问题分解为两个聚类问题和一个低维预测问题

调整目标属性组合的预测误差权重。考虑到广告商对目标属性组合的印象感兴趣，每一个S'_{ij}的准确性不应该相等。我们使用γ作为合同确定的目标用户和请求属性组合的集合。$S^t(\gamma)=\sum_{(i,j)\epsilon\gamma}S_{ij}^t$定义了在$\gamma$中第 t 天目标属性组合的实际总印象。$S'^t(\gamma)$是$S^t(\gamma)$对应的估计值。$\pi(\gamma)$是目标属性组合的概率分布。那么我们可以用重新加权的损失函数来衡量目标属性组合的预测误差:

$$L_R=\frac{1}{M}\sum_{t=1}^{M}\sum_{\gamma\epsilon\Gamma}\pi(\gamma)\left|\sum_{(i,j)\epsilon\gamma}S_{ij}'^{N+t}-\sum_{(i,j)\epsilon\gamma}S_{ij}^{N+t}\right| \quad (1)$$

这一损失表明可能存在交货不足的情况，是我们主要的最小化目标

用户聚类。为了获得矩阵，我们把所有的个体用户放入由现有合同中流行的目标用户属性组合决定的组中(约10^4)。例如，我们把来自上海的女性 iPhone 用户放在同一个用户组中。设G是所有用户组的集合，$G(i)\in G$代表用户 i 的组，用户组g在第 t 天的总印象量$\sum_{\{i:G(i)=g\}}S_{ij}^t$，包含的印象量更密集，更容易预测。基于用户聚类，我们可以定义以下损失度量用户群体预测印象的结构误差:

$$L_U=\frac{1}{M}\frac{1}{|G|}\frac{1}{|J|}\sum_{t=1}^{M}\sum_{J}\sum_{g\epsilon G}\left|\sum_{\{i:G(i)=g\}}S_{ij}'^{N+t}-\sum_{\{i:G(i)=g\}}S_{ij}^{N+t}\right| \quad (2)$$

该损失用于防止模型对历史契约的目标属性组合过拟合。

请求聚类。为了有效地得到矩阵 C,我们将每个用户的实际日印象向量聚为K_2簇。这里，用户的日印象向量是他/她在流行的目标属性组合(基于历史合同的统计数据预定义的)中的实际印象的日直方图。设所有用户的日印象向量集合为 V，将其分为K_2簇$V_1,V_2,\dots,V_{K_2}$。设μ_c为 c 簇的中心向量，$\sum_c^{-1}$表示 c 簇的协方差矩阵，则用欧氏距离定义聚类目标函数为

$$L_C=\sum_{c=1}^{K}\sum_{x_i\epsilon V_c}(x_i-\mu_c)^2 \quad (3)$$

如果我们考虑混合软聚类，聚类任务的目标函数也可以用马氏距离定义为$L_C=\sum_{c=1}^{K}\sum_{x_i\epsilon V_c}(x_i-\mu_c)^T\sum_c^{-1}(x_i-\mu_c)$。我们对$L_C$进行聚类最小化，得到矩阵 C。在我们的实现中，我们使用[13]中的算法确定聚类的数量，通过 k-means 得到 15 个聚类。我们使用两个月的真实历史数据(2018 年 10 月至 11 月)来评估聚类结果的一致性。每周聚类结果表明，至少有 12/15 个聚类中心在任何两周之间重叠。聚类是相对稳定和时间无关的，这符合我们的设计。因此，矩阵 C 不需要经常更新。

多目标损失函数及其预测。结合 Eq.(1)， Eq.(2)， Eq.(3)得到完全目标:

$$L_F=L_R+\lambda_uL_u+\lambda_cL_c \quad (4)$$

这里，λ_u和λ_c平衡多个目标的参数。由于张量 B 的尺度比原始张量 D 小得多，我们可以使用[10]中的深度时空张量分解模型(ST-TF)来预测 B 中的未知值(图 3 中张量 B 中的蓝色部分)，从而最小化目标函数L_F。预测值反映了未来用户群和请求簇的联合概率分布。现在我们已经得到了矩阵 A、C 和张量 B，因此我们可以计算原始张量中的蓝色部分，即预测的 M 日库存。

实现。在我们的实现中，我们不需要基于所有历史用户来构建原始张量。我们只关注最近活跃的用户，这导致了更小的 I。对于深度学习模型的训练，我们在一个时间窗口内每千名用户中抽取一个作为训练样本，以减少训练数据的大小。我们的设计显著降低了大张量分解的时间复杂性，并减轻了高维稀疏数据预测的困难。我们已部署系统的预测准确率为 88% ~ 92%,这大大有利于请求级别的印象销售和服务。

5 印象分配

现在我们已经得到了预测印象S_{ij}。在这一节中，我们将介绍如何在销售和服务阶段将这些印象优化分配到广告商的合同中。首先，我们将提出基本配置优化问题的公式。然后，我们设计了一种新的方法来有效地解决大规模的最优分配问题。最后定义了广告销售与服务的分配问题，并给出了系统设计。

5.1 基本分配问题的制定

回想一下，广告分配问题通常被建模为带有附加约束的二部匹配问题的变体，如图 1 所示。在保证交付广告中，在保证交付广告中，一个需求合同 k 对于欠交付

u_k通常有一个惩罚系数p_k（即展示次数少于d_k）。我们需要确定最优分配x_{ijk}，即分配给合同 k 的印象s_{ij}的比例。如果满足基本的需求和供应约束[2]以及一些额外的约束，如频率，那么分配是可行的。最优分配是将某个目标函数最小化的可行分配。保证投放广告的一个典型目标是最大化代表性和最小化惩罚之间的权衡。我们的目标是支持任意定制的线性约束，实现大规模问题的高效解决，特别是印象销售和广告服务。这里，我们以频率约束为例，定义一个基本的最优分配问题如下：

$$\min f(x_{ijk}) = \frac{1}{2}\sum_k \sum_{i,j\epsilon\Gamma(k)} \frac{V_k S_{ij}}{\theta_k}(x_{ijk} - \theta_k)^2 + \sum_k p_k u_k \tag{5}$$

s.t. $\forall k \quad \sum_{i,j\epsilon\Gamma(k)} x_{ijk} s_{ij} + u_k \geq d_k$ 需求约束条件

$\forall i,j \quad \sum_{k\epsilon\Gamma(i,j)} x_{ijk} \leq 1$ 供给约束

$\forall i,k \quad \sum_{j\epsilon\Gamma(k)} x_{ijk} s_{ij} \leq q_k$ 频率约束

$\forall i,j,k \quad x_{ijk} \geq 0, u_k \geq 0$ 非负性约束

这里，$\Gamma(k)$是需求节点 k 的邻域，同理，$\Gamma(i,j)$是供给节点 ij 的邻域。在目标函数中，第一项是测量L_2距离分配x_{ijk}到目标θ_k的非代表性。与已有的工作类似，设$\theta_k = \frac{d_k}{\sum_{i,j\epsilon\Gamma(k)} s_{ij}}$，$V_k$为契约 k 的相对优先级。目标函数中的第二个术语是分娩不足的总惩罚。

约束。频率限制控制了每个用户应该看到同一合同广告的最大/最小次数。在我们的设计中，合同频率约束很容易被其他线性约束取代，如广告频率约束（最大/最小数量的时间每个用户会看到相同的广告客户的广告），槽约束（广告的最大数量相同的合同/广告客户在每个用户请求），达到（最小数量的独特的个体应该看到广告客户的广告）和日常需求约束的合同

5.2 优化算法

式(5)中的分配问题是一个带线性约束的凸优化问题。存在一组解$x_{ijk} = 0$来满足约束条件。因此，我们可以根据 KKT 条件求解原问题的对偶问题，从而找到原问题的最优解。对于式(5)中的问题，拉格朗日函数为$L(x, u, \alpha, \beta, \gamma, \eta, \psi)$

$$= \frac{1}{2}\sum_k \left(\sum_{i,j\epsilon\Gamma(k)} \frac{V_k S_{ij}}{\theta_k}\left(x_{ijk} - \theta_k\right)^2 + \sum_k p_k u_k \right)$$

$$- \sum_k \alpha_k \left(\sum_{i,j\epsilon\Gamma(k)} x_{ijk} s_{ij} + u_k - d_k \right) + \sum_i \sum_j \beta_{ij} \left(\sum_{k\epsilon\Gamma(i,j)} x_{ijk} s_{ij} - s_{ij} \right)$$

$$+ \sum_i \sum_j \gamma_{ik} \left(\sum_{j\epsilon\Gamma_j(k)} x_{ijk} s_{ij} - q_k \right) \sum_i \sum_j \sum_k n_{ijk} x_{ijk} - \sum_k \psi_k u_k$$

根据稳态条件$\frac{\partial L}{\partial x_{ijk}} = 0$和$\frac{\partial L}{\partial u_k} = 0$，我们有$x_{ijk} = \theta_k \left(1 + \frac{\alpha_k - \beta_{ij} - \gamma_{ik} - \eta_{ijk}}{V_k}\right), 0 \leq \alpha_j \leq p_j$。因为$\eta_{ijk} = 0$或$x_{ijk} = 0$，所以分配是

$$x_{ijk} = max\{0, \theta_k(1 + \frac{\alpha_k - \beta_{ij} - \gamma_{ik}}{V_k})\} \tag{6}$$

为了求解对偶变量α_k，β_{ij}，γ_{ik}，我们可以得到这些对偶变量的梯度：$\frac{\partial L}{\partial \alpha_k} = d_k - \sum_{(i,j)\epsilon\Gamma(k)} x_{ijk}$，$\frac{\partial L}{\partial \beta_{ij}} = \sum_{(k)\epsilon\Gamma(i,j)} x_{ijk} - 1$，$\frac{\partial L}{\partial \gamma_{ik}} = \sum_{j\epsilon\Gamma_j(k)} x_{ijk} s_{ij} - q_k$。使用坐标下降法或梯度下

降法，我们可以迭代地解决问题，直到目标函数收敛。在每次迭代中，我们首先计算α，β，γ，然后得到x_{ijk}。由于每个线性约束都有一个对应的对偶变量，所以我们可以用同样的方法求解其他线性约束的优化问题。

5.3 高效的算法实现

理论上，梯度下降算法能够找到最优分配。然而，在实际应用中，问题的极大规模给算法的实现带来了严峻的挑战。

观察。在用户 i 不符合契约 k 条件的情况下，我们有$\forall j, x_{ijk} = 0$。由于$\gamma_{ik} = 0$或$\sum_{j\epsilon\Gamma_j(k)} x_{ijk}s_{ij} = q_k$，那么在这种情况下$\gamma_{ik} = 0$。在请求 j 不符合合同 k 条件的情况下，我们有$\forall i, x_{ijk} = 0$。根据我们部署的系统统计，$\frac{|\{x_{ijk}|x_{ijk}\neq 0\}|}{|I||J||K|} < 2.7\%$，$\frac{|\{\gamma_{ik}|\gamma_{ik}\neq 0\}|}{|I||K|} < 3\%$。因此，对偶变量$\gamma_{ik}$是非常稀疏的，所以在二部图的边。此外，$\alpha_k$的规模相对较小。只有变量$\beta_{ij}$是密集的，因为几乎每个用户 i 都有大量的请求，所以$s_{ij} \neq 0$。这些观察激励我们利用并行计算和 GPU 加速计算的能力来实现我们的算法，这将显著加快问题解决的速度。

并行算法。我们使用了一组工作者来有效地解决这个问题，每个工作者在局部计算一个β_{ij}子集，并通过一个参数服务器-彼此共享α_k和非零γ_{ik}。由于α的尺度很小，α的非常稀疏，参数共享的代价很小。具体来说，将所有用户分为 w 组，每组分配给一个工作者。然后并行计算如下循环:1)每个工作者从参数服务器下载最新的α_k和非零γ_{ik};2) 每个工作者根据 Eq.(6)和更新和本地β_{ij}计算x_{ijk}给自己的用户组 3)各工作者计算并上传$\Delta\alpha_k$和非零γ_{ik}给参数服务器;4)参数服务器从所有工作者中聚合$\Delta\alpha_k$和$\Delta\gamma_{ik}$，生成新的α_k和γ_{ik}。这个循环一直持续到目标函数收敛为止。

GPU-Accelerated 计算。对于每个工人来说，逐个计算x_{ijk}的值(式(6))是最耗时的步骤。为了进一步加快计算速度，我们把所有的参数α_k， β_{ij}和γ_{ik}都打包成三个等大小的张量。这样，每个工作者都可以利用 GPU 的能力有效地计算x_{ijk}张量。考虑到x_{ijk}是非常稀疏的，基于二部图中的边，我们可以对张量进行压缩，只保留那些非零维。这样，大大降低了计算成本。

5.4 销售分配

在销售阶段，广告客户的订单一次到达一个。出版商将预测库存分配给每个新订单并签订合同。主要目标是最好地满足现有合同的要求。第二个目标是最大化新订单的销售印象。为了在短时间内处理数月的印象和数千份合约，我们利用了一个由三层组成的 lambda 架构:离线分配、在线分配和响应订单的服务层。

离线分配销售。离线分配有足够的时间来搜索已签合同的全局最优解。在销售几个月的印象时，更好的时间平滑性是更好的广告服务节奏的重要保证。因此，我们在式(5)中的基本分配问题上增加了每日需求约束和每日欠交惩罚。

线下分配销售的目标函数为：

$$\sum_k \sum_{i,j\epsilon\Gamma(k)} \frac{V_k S_{ij}}{\theta_k}(x_{ijk} - \theta_k)^2 + \sum_k p_k u_k$$

$$\min \quad f(x_{ijk}) - \sum_t \sum_{k\epsilon\Gamma(t)} p_k^t w_k^t$$

$$s.t. \quad \forall k,t \qquad \sum_{i,j\epsilon\Gamma(k,t)} x_{ijk}s_{ij} + w_k^t \geq d_k^t \qquad (7)$$

这里d_k^t是合同 k 第 t 天印象的保证交付量。它可以由广告客户或发布者指定。w_k^t是指合同 k 在第 t 天未交货。p_k^t是契约 k 在第 t 天的惩罚系数，p_k^t通常是 t 的递减函数。我们在 5.3 节中使用基于 GPU 集群的并行算法来解决这个问题。

在线分配销售。在线分配以一分之一分钟的延迟处理新到达的订单。出版商的目标是最好地满足新订单的需求，同时将对现有合同分配的负面影响降至最低。我们为基本问题增加了新秩序的目标和约束:

$$\min \quad f(x_{ijk}) - \sum_{I}\sum_{J} y_{ij}$$

$$s.t. \quad \forall i,j \qquad \sum_{k\epsilon\Gamma(i,j)} x_{ijk}y_{ij} \le 1,\ \sum_{j\epsilon\Gamma(y)} y_{ij}s_{ij} \le q,\ y_{ij} \ge 0 \qquad (8)$$

这里，y_{ij}是分配给新订单的供应比例。q 是新阶次的频率约束。基于离线全局最优解，该问题可以用较少的迭代次数求解，从而获得较短的响应延迟。

5.5 服务分配

在服务期间，用户请求一次到达一个，每个请求提供几个印象。发行商将每个印象实时分配到合同中，以优化目标。在我们的设计中，我们在基本分配问题(式(5))的基础上增加了一个次要目标，以提高总点击率(CTR)。目标函数是:

$$\min \quad f(x_{ijk}) - \lambda \sum_{k} \sum_{i,j\epsilon\Gamma(k)} \omega_k x_{ijk} ctr_{ijk}$$

在这里，ctr_{ijk}是合同 k 在印象s_{ij}上的点击率. ctr_{ijk}是由广告系统的点击率预测组件提供的。ω_k为合同 k 的 CTR 的权重。λ为平衡不同目标的超参数。

根据提前一天的预测印象，我们使用 5.3 节的方法生成分配计划来指导广告服务。为了更好的应对新到订单带来的印象预测错误和实时需求变化，我们需要根据实时反馈，频繁的修改分配计划。根据式(6)，设$\rho_{ijk} = 1 + \frac{\alpha_k - \beta_{ij} - \Upsilon_{ik}}{v_k}$，有$x_{ijk} = \max\{0, \theta_{ik}\rho_{ijk}\}$。这里的$\rho_{ijk}$是由二部图确定的。它需要每分钟更新一次。

$\theta_k = \frac{d_k}{\sum_{i,j\epsilon\Gamma(k)} s_{ij}}$需要根据实时的$d_k$和$s_{ij}$进行更新。为了使目标函数最小化，在线服务采取以下步骤。1)基于预测印象和已签合同生成二部图。考虑印象预测和需求的基本时间单位均为日，每小时更新二部图即可。2)根据实时(毫秒级)的印象和契约统计，更新d_k, s_{ij}和θ_k。3)给出二部图和实时d_k和s_{ij}，在线分配组件解决优化问题(式(9))，并输出张量x_{ijk}和张量p_{ijk}。这个计算每分钟进行一次。4)在线服务组件以p_{ijk}和θ_k为输入，计算最终的x_{ijk}和相应服务广告。

6 系统评估

我们已经实施了 RAP，并在腾讯在线保送广告系统中部署了近一年。该系统为数十亿级用户提供各种广告，包括视频广告、推送广告、闪屏广告等。RAP 的部署带来了显著的收入增长

6.1 数据集

在本节中，我们利用腾讯在线视频网站的真实印象和合同数据，对 RAP 进行广泛的评价。

为预测数据集。每天有十亿次的印象。每个印象有四种用户属性和 17 种请求属性。用户属性包括平台(有 7 个选项，如 iPhone 和 PC)，区域(有 396 个选项，如上海)，年龄和性别。请求属性包括内容类型(有超过 300 个选项，如电影和电视)、内容名称(有超过 340 万个选项，如“蜘蛛侠”和“朋友”)、网络(5 个选项，如 Wi-Fi 和 4G)、目标时间(有 48 个选项，每半个小时是一个选项)等。训练数据为 2018 年 6 月 1 日至 2019 年 11 月 30 日，测试数据为 2019 年 12 月 1 日至 2019 年 12 月 31 日。

数据集分配。为了评估销售分配，我们在 2020 年 1 月 1 日使用了 650223 个抽样印象和 5753 个合同。为了评估服务分配，我们使用了 2019 年 12 月 31 日的两个数据集。一个大型数据集包含 726390 个采样印象和 5782 个合同。一个小数据集包含 9087 个抽样印象和 104 个来自上海的合同。除非另有说明，评估是在使用 Tesla P40 GPU 和 Intel Xeon CPU E5-2680 v4 的服务器上进行的。

6.2 印象预测

模型的比较。[10]的评价结果表明，传统的时间序列预测方法不能很好地处理稀疏的高维数据。因此，我们采用以下最先进的高维时间序列预测模型进行比较:ST-TF[10]、TRMF[1]、CNN 模型和 LSTM。这些模型的结构和参数与[10]模型一致。

如果我们考虑所有有效的印象属性，属性组合的数量对于以前的模型来说太大了。为了进行公平的比较，我们首先考虑三个最流行的属性，即平台、区域和内容类型(PAC)。然后我们考虑五个最受欢迎的属性，即平台、区域和网络、性别和内容类型(PANGC)。在此基础上，对实际契约的所有目标属性组合进行了评价。

利用 PAC 属性组合提前 N 天预测印象。设$N = \{1,2, \cdots 28\}$，图 4 为不同方法随 N 变化的预测精度，表 1 为 28 天平均预测精度。结果表明，我们的设计比 TRMF、CNN 和 LSTM 的精度显著提高。总的来说，RAP 的表现要优于 ST-TF。RAP 的 28 天平均准确率为 87.76%，ST-TF 的 28 天平均准确率为 86.53%。当 N 较小时，ST-TF 的精度略好。随着 N 的增加，RAP 的准确率逐渐超过 ST-TF。

Method	Accuracy	# of Parameters	Training Time (s)
RAP	**0.8776**	137,462	1,393
ST-TF	0.8653	61,850	942
TRMF	0.8139	1,800,879	1,127
CNN	0.8028	174,748	815
LSTM	0.6858	8,716	1,213

表 1:不同模型在 PAC 属性组合下的 28 天平均预测精度。

PANGC 属性组合的性能。规模是 PAC 病例的 15 倍。面对高维张量，TRMF、CNN 和 LSTM 在可接受的训练时间内都无法收敛。图 5 展示了 ST-TF 在 PAC 和 PANGC 案例中的训练过程。在 PAC 情况下，ST-TF 损失稳步下降，700 步后趋于收敛。在 PANGC 的情况下，下跌后的损失在 0.2 左右震荡，很难收敛。添加两个属性(网络和性别)将 ST-TF 的准确性降低约 6%。考虑的属性越多，ST-TF 的性能就越差。结果表明，这些最先进的方法不能处理高维稀疏数据，因此不能解决我们的请求级印象预测任务。

所有目标属性组合的性能。在这种情况下，我们考虑真实契约所针对的所有属性组合。除 RAP 模型外，其他模型均无法产生预测结果。表 2 为 RAP 的预测精度。当 N = 1、7 和 14 时，准确率分别为 90.13%、91.76%和 89.87%，甚至略优于 PAC 情况下的准确率。**在我们部署的系统中,所有目标属性组合的预测准确率为 88% ~ 92%。结果表明，我们的设计能够实现高效、准确的大规模请求级印象预测。**

与抽样方法比较。如前所述，现有的基于深度学习的方法在考虑所有属性组合时并不有效。在工业应用中，通常采用历史数据的抽样结果作为预测。因此，我们将我们的方法与以下广泛使用的抽样方法进行了比较:1)传统抽样(TS)对一定比例的每日历史数据进行抽样;2)平滑采样(Smooth sampling, SS)使用一个 30 天的滑动窗口对多日历史数据的平均值进行采样。表 2 给出了不同抽样方法对 PAC 属性组合和所有目标属性组合的预测精度。与两种抽样方法相比，我们的方法有了明显的改进，在所有情况下都是最好的。

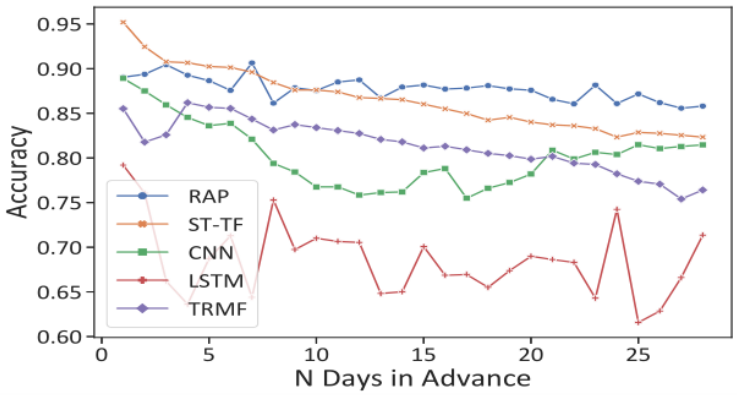


图 4：提前 N 天的 PAC 属性组合的印象预测精度

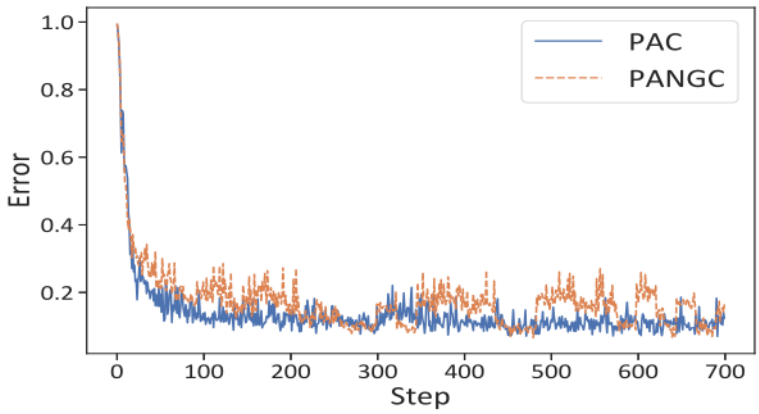


图 5:PAC 和 PANGC 中 ST-TF 的训练过程

6.3 印象分配

1)销售分配

回想一下，RAP 利用 lambda 架构，解决了离线分配问题(见 Eq.(7))和在线分配问题(见 Eq.(7))，以优化订单印象分配。我们将我们的销售策略与以下方法进行比较：

Method	Contract Targets			PAC		
	1	7	14	1	7	14
RAP	90.13	91.76	89.87	89.04	90.65	87.95
SS	74.03	73.91	74.27	74.03	73.91	74.27
TS	87.84	86.10	87.61	86.98	84.39	77.62

表 2:不同目标属性组合提前 n 天的预测精度。

	Time (s)	# of Saleable Impressions
FIFO	0.1	182
Heuristic-HWM	1	3688
RAP	30	4906

表 3:不同方法分配给新订单的平均销售印象数。

•**先进先出**:一个新到的订单的优先级低于所有签署的合同。因此，保持对已签署合同的分配不变，只有其余符合条件的印象才能分配给新订单。

•**启发式-HWM:**我们采用 HWM[4]来分配印象到一个新订单。具体来说，我们首先确定新顺序可用印象的上界和下界。上界是总印数，下界是 FIFO 的结果。然后，利用二分搜索的方法，给新订单一个在上界和下界之间的预定量，将销售问题转化为一系列典型的交货问题。我们通过 HWM 解决每个交货问题，直到我们找到最大的可用库存，不会增加已签署的合同的欠交货率。

考虑到 2020 年 1 月 1 日的真实 650223 个印象和 5753 个合同，我们从 5753 个合同中随机抽取 100 个订单作为新订单，其他合同继续签订。表 3 给出了通过不同方法分配给每个新订单的平均销售印象数量。FIFO 表现最差。**与 Heuristic-HWM 相比，RAP 将新订单的销售印象增加了 33%，这意味着收入增加了 33%。**RAP 对每个新订单的分配时间成本为 30 秒，启发式- hwm 的分配时间成本为 1 秒。在我们部署的系统中，对于大多数订单来说，分分钟的延迟是可以接受的，因此 RAP 带来了显著的收入提升。对于一些对延迟敏感的订单，我们使用启发式 hwm 来实现即时响应。

2)服务分配

对于不同的服务方式，我们评估以下指标：

•未交付率:表示未交付印象占总保证需求的比例。它是主要的最小化目标，定义为$U=\frac{\sum_k u_k}{\sum_k d_k}$。

•游戏体验率:代表呈现的印象占总印象的比例。更高的播放率意味着更好地利用广告机会，从而获得更高的发行商利润。播放速率定义为$P=\frac{\sum_k \sum_{i,j\epsilon\Gamma(k)} s_{ij} x_{ijk}}{\sum_i \sum_j s_{ij}}$

•L2 距离:度量生成的分配偏离目标函数$L_2=\frac{1}{2}\sum_k \sum_{i,j\epsilon\Gamma(k)} \frac{v_k s_{ij}}{\theta_k}(x_{ijk}-\theta_k)^2$

•点击率(CTR):是总点击率除以总展示次数。

•时间成本:包括初始化时间成本和每次迭代的平均时间成本。

方法比较。我们实现了以下最先进的方法，并与我们的方法进行了比较:HWM[4]、SHALE[2]和 ALI[5]。特别地，我们考虑了 ALI[5]的三种变量:1)原始 ALI 分别用梯度下降法和坐标下降法计算对偶变量 α 和 β;2) ALI_CD 只使用坐标下降法;3) ALI_GDuses only a gradient descent method。RAP_CD:用坐标下降法求解方程(5)中基本问题的对偶变量α、β和γ;2) RAP_GD:采用梯度下降法解决基本问题;3)RAP_CD_ CTR:采用坐标下降法，以 CTR 最大化为次要目标，求解式(9)中的细化问题。RAP_GD_CTR:用户使用梯度下降法来解决细化的问题。

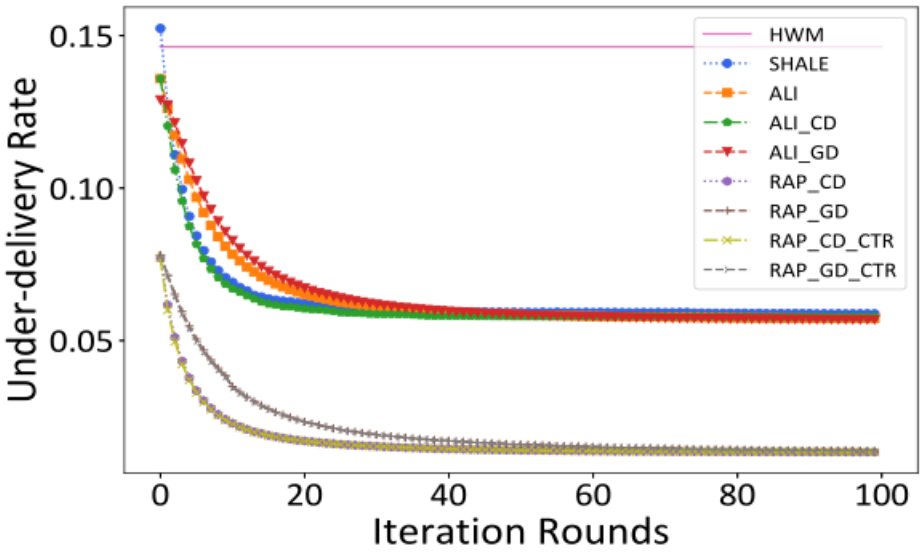


图 6:欠交付率随着大型数据集上的迭代而变化

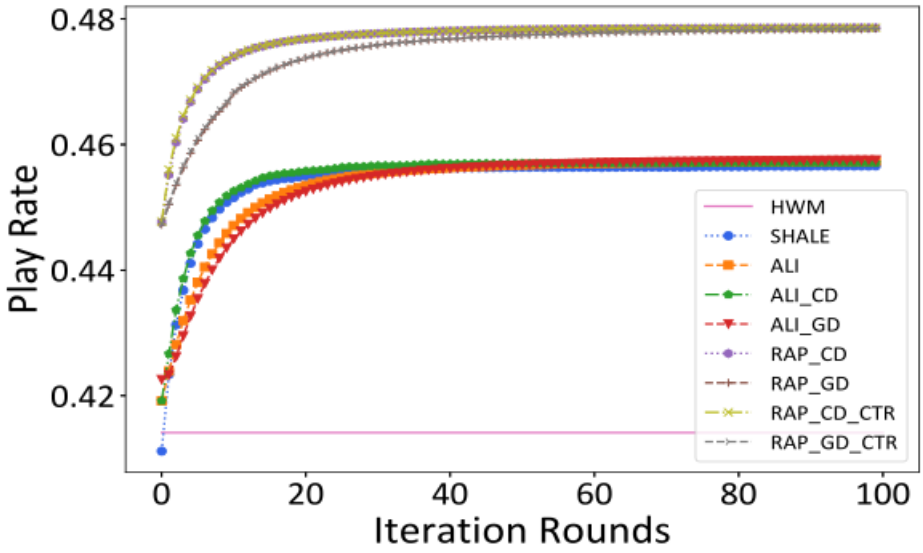


图 7:随着大型数据集的迭代，播放率会发生变化

Algorithm	U	P	CTR	L_2	Init Time	Avg Time
HWM	0.1463	0.4141	0.0312	0.0292×10^4	114.8751	-
SHALE	0.0588	0.4566	0.0312	6.0951×10^4	114.8361	0.9116
ALI	0.0573	0.4573	0.0327	6.2012×10^4	148.4866	0.2411
ALI_CD	0.0578	0.4571	0.0327	6.2486×10^4	144.7784	0.9112
ALI_GD	0.0568	0.4575	0.0327	6.0871×10^4	146.9235	0.0494
RAP_CD	0.0134	0.4786	0.0312	8.5062×10^4	251.9034	1.1356
RAP_GD	0.0137	0.4784	0.0312	7.8719×10^4	258.9217	0.0689
RAP_CD_CTR	**0.0134**	**0.4786**	**0.0327**	8.5250×10^4	248.8460	1.1285
RAP_GD_CTR	0.0137	0.4785	0.0327	7.9012×10^4	261.8263	0.0709

表 4:100 次迭代后不同方法在大型数据集上的性能(U 是欠交付率，P 是播放率，Avg 时间是每次迭代的平均时间)

Algorithm	U	P	CTR	L_2	Init Time	Avg Time
HWM	0.1847	0.8336	0.0309	0.564×10^3	0.5602	-
SHALE	0.0862	0.9343	0.0308	2.789×10^3	2.3205	0.0504
ALI	0.0902	0.9302	0.0324	2.205×10^3	2.3772	0.0156
ALI_CD	0.0861	0.9345	0.0324	2.495×10^3	2.3343	0.0526
ALI_GD	0.0894	0.9311	0.0324	2.082×10^3	2.3300	0.0034
RAP_CD	0.0453	**0.9762**	0.0309	3.449×10^3	4.1851	0.0695
RAP_GD	0.0484	0.9731	0.0309	3.048×10^4	4.1926	0.0047
RAP_CD_CTR	**0.0453**	0.9761	**0.0324**	3.435×10^4	4.2138	0.0698
RAP_GD_CTR	0.0484	0.9730	0.0324	3.040×10^4	4.3696	0.0026

表 5:100 次迭代后不同方法在小数据集上的性能(U 为欠交付率，P 为播放率，Avg Time 为每次迭代的平均时间)

图 6 和图 7 说明了在大型数据集上，交付不足率和播放率随迭代的变化(726,390 次印象和 5,782 份合同)。在小数据集上的结果非常相似。表 4 和表 5 展示了不同方法经过 100 次迭代后的所有指标。由于 HWM 只有一次迭代，它花费的时间最少，但导致最糟糕的欠交付率。ALI 和 SHALE 这三种型号的井均达到了类似的欠交货率、开采率和L_2距离。但阿里的各种版本比页岩油花费的时间要少得多。从图 6 和图 7 的明显差距可以看出，**RAP 的变体与现有的方法相比，实现了显著的改进，其未交**

付率最低，播放率最高。对于我们部署的系统，交付不足率为 3% ~ 5%。例如，RAP_GD_CTR 在大数据集上的欠交付率为 1.34%，比 ALI_GD 低 4.34%。RAP_GD_CTR 的播放速率在大数据集上为 47.86%，比 ALI_GD 高出 2.11%。RAP_GD_CTR 在小数据集上的播放率达到 97.61%。RAP 的L_2距离略大于 SHALE 和 ALI，代表性略有丧失。在 RAP 的各种变体中，我们可以看到使用梯度方法可以减少一个数量级的时间成本，而不足交付率和播放率的损失可以忽略不计。例如，RAP_GD_CTR 只消耗 RAP_CD_CTR 的 6.3%时间。对于 100 次迭代，RAP_GD_CTR 在大数据集上花费 7.1 秒，在小数据集上花费 0.26 秒。表 4 和表 5 的结果还表明，在 Eq.(9)中添加次要 CTR 最大化目标后，两个数据集的 CTR 均略有提高 0.15%。

时间成本。对于基本的 CPU 解决方案(在 5.2 节中)，我们使用 56 核 Intel Xeon CPU E5-2680 v4，每次迭代的成本为 43.68 秒。对于 5.3 节中 GPU 加速的并行解决方案，我们使用 4 特斯拉 P40 GPU，每次迭代花费 0.809 秒。结果表明，该设计可节省 98.1%的时间成本。

7 结论

我们提出了一个大规模保证投放的广告策划系统的整体设计，支持高效的请求级印象预测和分配。我们的系统让广告主在保持高投放率和播放率的同时，实现足够精准的投放目标，显著提高发行商的收入和广告主的投资回报。它还可以提供更用户友好的广告服务，能够处理一组定制的线性服务约束。

致谢

国家自然科学基金面上项目(No. 61822209, No. 61932016, No. 61751211);国家杰出青年科学基金面上项目(No.61625205);中央高校基本科研业务费专项资金资助。

参考文献

[1] Mohammad Taha Bahadori, Qi Rose Yu, and Yan Liu. 2014. Fast multivariate spatio-temporal analysis via low rank tensor learning. In NIPS. 3491 – 3499.

[2] Vijay Bharadwaj, Peiji Chen, Wenjing Ma, Chandrashekhar Nagarajan, John Tomlin, Sergei Vassilvitskii, Erik Vee, and Jian Yang. 2012. Shale: an efficient algorithm for allocation of guaranteed display advertising. In ACM SIGKDD.1195 – 1203.

[3] Preeti Bhargava, Thomas Phan, Jiayu Zhou, and Juhan Lee. 2015. Who, what, when, and where: Multi-dimensional collaborative recommendations using tensor factorization on sparse user-generated data. In WWW. ACM.

[4] Peiji Chen, Wenjing Ma, Srinath Mandalapu, Chandrashekhar Nagarjan, Jayavel Shanmugasundaram, Sergei Vassilvitskii, Erik Vee, Manfai Yu, and Jason Zien. 2012. Ad serving using a compact allocation plan. In 13th ACM Conference on Electronic Commerce. 319 – 336.

[5] Zhen Fang, Yang Li, Chuanren Liu, Wenxiang Zhu, Yu Zheng, and Wenjun Zhou. 2019. Large-Scale Personalized Delivery for Guaranteed Display Advertising with Real-Time Pacing. In ICDM. IEEE, 190 – 199.

[6] Jon Feldman, Aranyak Mehta, Vahab Mirrokni, and Shan Muthukrishnan. 2009. Online stochastic matching: Beating 1-1/e. In 50th Annual IEEE Symposium on Foundations of Computer Science. IEEE, 117–126.

[7] Ali Hojjat, John Turner, Suleyman Cetintas, and Jian Yang. 2014. Delivering guaranteed display ads under reach and frequency requirements. In AAAI.

[8] Ali Hojjat, John Turner, Suleyman Cetintas, and Jian Yang. 2017. A unified framework for the scheduling of guaranteed targeted display advertising under reach and frequency requirements. Operations Research 65, 2 (2017), 289–313.

[9] Chinmay Karande, Aranyak Mehta, and Pushkar Tripathi. 2011. Online bipartite matching with unknown distributions. In 43rd annual ACM symposium on Theory of computing. 587–596.

[10] Xiaoyang Ma, Lan Zhang, Lan Xu, Zhicheng Liu, Ge Chen, Zhili Xiao, Yang Wang, and Zhengtao Wu. 2019. Large-scale User Visits Understanding and Forecasting with Deep Spatial-Temporal Tensor Factorization Framework. In ACM SIGKDD. 2403–2411.

[11] Vahab S Mirrokni, Shayan Oveis Gharan, and Morteza Zadimoghaddam. 2012. Simultaneous approximations for adversarial and stochastic online budgeted allocation. In 23rd annual ACM-SIAM symposium on Discrete Algorithms. SIAM, 1690–1701.

[12] Erik Vee, Sergei Vassilvitskii, and Jayavel Shanmugasundaram. 2010. Optimal online assignment with forecasts. In 11th ACM conference on Electronic commerce. 109–118.

[13] Ulrike Von Luxburg et al. 2010. Clustering stability: an overview. Foundations and Trends® in Machine Learning 2, 3 (2010), 235–274.

[14] Jia Zhang, Zheng Wang, Qian Li, Jialin Zhang, Yanyan Lan, Qiang Li, and Xiaom- ing Sun. 2017. Efficient delivery policy to minimize user traffic consumption in guaranteed advertising. In AAAI.